Analiza i Przetwarzanie Dzwięku

Rok akademicki 2025/26

Projekt 1

Analiza cech sygnału audio w dziedzinie czasu

Ryszard Czarnecki
Józef Dubois

Kwiecień 2026

Contents

1 Opis aplikacji **2**
1.1 Struktura projektu . . . 2
1.2 Użyte biblioteki . . . 2
1.3 Interfejs użytkownika . . . 2

2 Opis metod **3**
2.1 Podział sygnału na ramki . . . 3
2.2 Głośność – Volume (RMS) . . . 3
2.3 Energia krótkoterminowa (STE) . . . 3
2.4 Współczynnik przejść przez zero (ZCR) . . . 4
2.5 Entropia energii . . . 4
2.6 Dyskretna transformata Fouriera (DFT) . . . 4
2.7 Cechy widmowe . . . 4
2.7.1 Środek ciężkości widma (Spectral Centroid) . . . 4
2.7.2 Częstotliwość graniczna widma (Spectral Rolloff) . . . 5
2.7.3 Płaskość widma (Spectral Flatness) . . . 5
2.8 Detekcja ciszy . . . 5
2.9 Częstotliwość tonu podstawowego (F_0) . . . 6
2.9.1 Metoda autokorelacji . . . 6
2.9.2 Metoda AMDF . . . 6
2.10 Klasyfikacja: dźwięczne / bezdźwięczne / cisza . . . 7
2.11 Parametry na poziomie klipu . . . 7
2.12 Rozróżnianie mowy i muzyki . . . 8

3 Prezentacja wyników **8**
3.1 Przebieg czasowy . . . 8
3.1.1 Kobieta . . . 8
3.1.2 Mężczyzna . . . 9
3.1.3 Muzyka (Mozart) . . . 9
3.2 Parametry ramkowe . . . 10
3.2.1 Kobieta . . . 10
3.2.2 Mężczyzna . . . 10
3.2.3 Muzyka (Mozart) . . . 11
3.3 Częstotliwość tonu podstawowego (F_0) . . . 11
3.3.1 Kobieta . . . 11
3.3.2 Mężczyzna . . . 12
3.3.3 Muzyka (Mozart) . . . 12
3.4 Klasyfikacja: dźwięczne / bezdźwięczne / cisza . . . 13
3.4.1 Kobieta . . . 13
3.4.2 Mężczyzna . . . 13
3.4.3 Muzyka (Mozart) . . . 13

4 Podsumowanie **14**

1 Opis aplikacji

Aplikacja została napisana w języku Python 3 i udostępniona jako interaktywna strona internetowa dzięki frameworkowi **Streamlit**. Użytkownik wczytuje plik `.wav` za pomocą widgetu *file_uploader*, po czym aplikacja automatycznie wykonuje analizę sygnału w dziedzinie czasu.

1.1 Struktura projektu

Kod podzielony jest na moduły umieszczone w katalogu `src/`:

- `wav_reader.py` – ręczne odczytywanie plików WAV (format PCM, obsługa 8/16/24/32 bit, konwersja stereo do mono),
- `parameters.py` – podział sygnału na ramki, obliczanie parametrów: Volume (RMS), STE, ZCR, entropia energii, środek ciężkości widma, częstotliwość graniczna widma, płaskość widma,
- `silence_detection.py` – detekcja ciszy na podstawie progu głośności,
- `pitch.py` – wyznaczanie częstotliwości tonu podstawowego F_0 metodami autokorelacji i AMDF,
- `voiced_unvoiced.py` – klasyfikacja ramek jako dźwięczne, bezdźwięczne lub cisza,
- `parameters_over_clip.py` – parametry na poziomie całego klipu (LSTER, HZCRR, ZSTD, entropia energii klipu).

Główny plik `app/main_app.py` łączy te moduły i tworzy interfejs użytkownika w Streamlit.

1.2 Użyte biblioteki

- **NumPy** – operacje na tablicach numerycznych, normalizacja próbek,
- **Matplotlib** – generowanie wykresów (przebieg czasowy, parametry, pitch, klasyfikacja),
- **Streamlit** – interfejs webowy z widgetami (suwaki, pola numeryczne, przyciski pobierania),
- **Pandas** – eksport parametrów do pliku CSV.

1.3 Interfejs użytkownika

Po wczytaniu pliku WAV interfejs wyświetla:

1. Informacje o pliku (częstotliwość próbkowania, liczba kanałów, głębia bitowa, czas trwania).
2. Przebieg czasowy sygnału.
3. Przycisk do włączania / wyłączania parametrów widma (mają one złożoność $O(n^2)$)

4. Wykresy parametrów na poziomie ramki z możliwością regulacji długości ramki i stosunku pokrywania się ramek za pomocą suwaków.
5. Statystyki (średnia, max, min, odchylenie standardowe).
6. Wizualizację detekcji ciszy.
7. Wykres częstotliwości tonu podstawowego F_0.
8. Klasyfikację dźwięczne / bezdźwięczne / cisza.
9. Parametry na poziomie klipu z prostą klasyfikacją mowa/muzyka.
10. Przycisk eksportu parametrów do CSV.

2 Opis metod

2.1 Podział sygnału na ramki

Sygnał dzielony jest na krótkie ramki o konfigurowalnej długości (domyślnie 20 ms) z określoną proporcją pokrywania się (domyślnie 50%). Długość ramki w próbkach wynosi:

$$N_{\text{ramki}} = \left\lfloor f_s \cdot \frac{T_{\text{ms}}}{1000} \right\rfloor \tag{1}$$

gdzie f_s to częstotliwość próbkowania, a T_{ms} – długość ramki w milisekundach.

2.2 Głośność – Volume (RMS)

Głośność ramki obliczana jest jako pierwiastek z średniej kwadratów próbek (Root Mean Square):

$$\text{Volume}(k) = \sqrt{\frac{1}{N} \sum_{n=0}^{N-1} x_k^2(n)} \tag{2}$$

gdzie $x_k(n)$ to n-ta próbka k-tej ramki, a N – długość ramki w próbkach. Parametr ten dobrze oddaje subiektywne wrażenie głośności sygnału.

2.3 Energia krótkoterminowa (STE)

Energia krótkoterminowa (Short-Time Energy) to średnia kwadratów próbek w ramce:

$$\text{STE}(k) = \frac{1}{N} \sum_{n=0}^{N-1} x_k^2(n) \tag{3}$$

STE jest ściśle związana z Volume — zachodzi relacja Volume $= \sqrt{\text{STE}}$. STE pozwala rozróżniać fragmenty o dużej energii (dźwięczne, głośne) od tych o niskiej (cisza, szum tła).

2.4 Współczynnik przejść przez zero (ZCR)

Zero Crossing Rate określa, jak często sygnał zmienia znak w obrębie ramki:

$$\mathrm{ZCR}(k) = \frac{1}{N} \sum_{n=1}^{N-1} 1_{\left[\mathrm{sgn}\left(x_k(n)\right) \neq \mathrm{sgn}\left(x_k(n-1)\right)\right]} \tag{4}$$

Wysoka wartość ZCR sugeruje obecność szumu lub głosek bezdźwięcznych (np. sybilantów), natomiast niska wartość jest charakterystyczna dla dźwięków tonalnych.

2.5 Entropia energii

Entropia energii mierzy nieprzewidywalność rozkładu energii wewnątrz ramki. Ramkę dzieli się na M podramek (domyślnie $M = 10$) i oblicza:

$$H_E(k) = -\sum_{j=1}^{M} p_j \log_2 p_j, \qquad p_j = \frac{E_j}{E_{\text{całk.}}} \tag{5}$$

gdzie E_j to energia j-tej podramki, a $E_{\text{całk.}}$ – energia całej ramki. Niska entropia oznacza, że energia jest skoncentrowana w kilku podramkach (np. impuls), a wysoka – że jest równomiernie rozłożona (np. szum).

2.6 Dyskretna transformata Fouriera (DFT)

Dyskretna transformata Fouriera przekształca sygnał z dziedziny czasu do dziedziny częstotliwości:

$$X(k) = \sum_{n=0}^{N-1} x(n)\, e^{-i2\pi \frac{kn}{N}}, \quad k = 0, 1, \ldots, N-1 \tag{6}$$

Na jej podstawie wyznacza się widmo amplitudowe $|X(k)|$, które opisuje rozkład energii sygnału w dziedzinie częstotliwości. Przed obliczeniem transformaty każda ramka mnożona jest przez okno Hanninga:

$$w(n) = \frac{1}{2}\left(1 - \cos\frac{2\pi n}{N-1}\right), \quad n = 0, 1, \ldots, N-1 \tag{7}$$

Zastosowanie okna redukuje przeciek widmowy (*spectral leakage*) wynikający ze skończonej długości ramki.

2.7 Cechy widmowe

2.7.1 Środek ciężkości widma (Spectral Centroid)

Środek ciężkości widma określa "średnią" częstotliwość sygnału w ramce ważoną jej widmem:

$$C = \frac{\sum_{k=0}^{N/2} f(k)\,|X(k)|}{\sum_{k=0}^{N/2} |X(k)|} \tag{8}$$

gdzie $f(k) = k \cdot f_s/N$ oznacza częstotliwość odpowiadającą indeksowi k, a sumowanie prowadzone jest po nieujemnych częstotliwościach (pierwsza połowa widma). Wysokie wartości centroidu odpowiadają sygnałom „jasnym”, zawierającym więcej składowych wysokoczęstotliwościowych.

2.7.2 Częstotliwość graniczna widma (Spectral Rolloff)

Częstotliwość graniczna określa taką częstotliwość f_r, poniżej której zawarta jest określona część sumy amplitud widma (w implementacji $\alpha = 0{,}85$):

$$\sum_{k=0}^{k_r} |X(k)| = \alpha \sum_{k=0}^{N/2} |X(k)|, \tag{9}$$

gdzie $\alpha \in (0, 1)$, a k_r odpowiada częstotliwości granicznej.

2.7.3 Płaskość widma (Spectral Flatness)

Płaskość widma mierzy, na ile widmo jest zbliżone do szumu białego (równomierne) lub do sygnału tonalnego (z dominującymi składowymi):

$$F = \frac{\left(\prod_{k=0}^{N/2} |X(k)|\right)^{2/(N+2)}}{\frac{2}{N+2} \sum_{k=0}^{N/2} |X(k)|} \tag{10}$$

Wartości bliskie 1 oznaczają widmo płaskie (szumowe), natomiast wartości bliskie 0 wskazują na charakter tonalny. Dla ramek o bardzo niskiej energii (cisza) przyjmuje się $F = 0$.

Przykładowe wykresy parametrów ramkowych

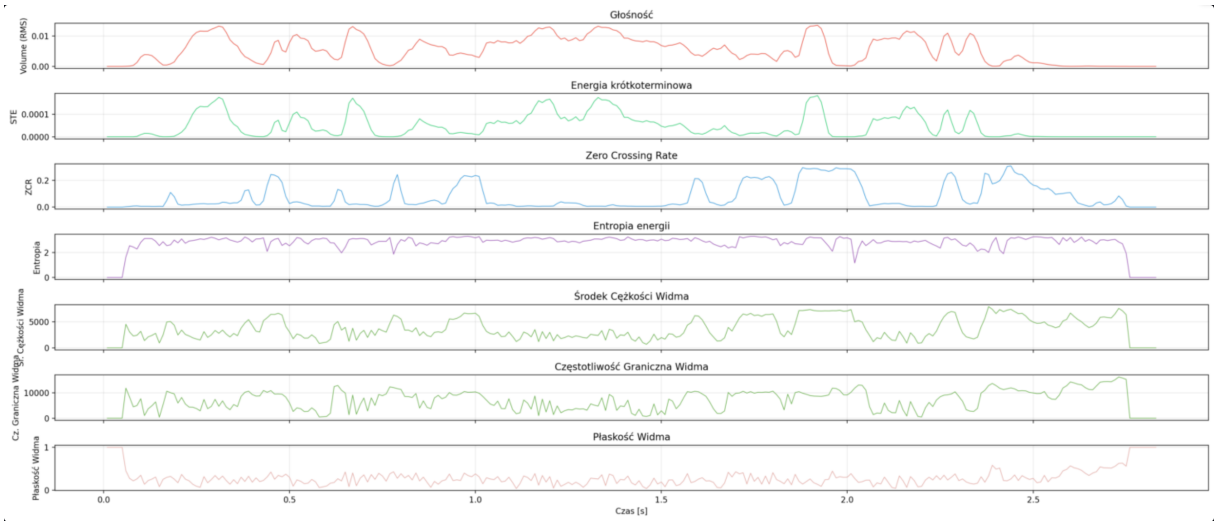

Figure 1: Przykładowe wykresy parametrów ramkowych sygnału audio.

2.8 Detekcja ciszy

Cisza wykrywana jest za pomocą prostego progowania głośności. Próg stanowi zadany procent maksymalnej głośności w całym sygnale:

$$\text{threshold} = r \cdot \max_k \Big(\text{Volume}(k)\Big) \tag{11}$$

gdzie $r \in [0{,}01;\ 0{,}30]$ jest regulowany przez użytkownika za pomocą suwaka. Ramka uznawana jest za cichą, jeśli jej głośność jest mniejsza od progu. Metoda ta jest prosta i skuteczna, choć wrażliwa na sygnały z niskim stosunkiem sygnał/szum (SNR).

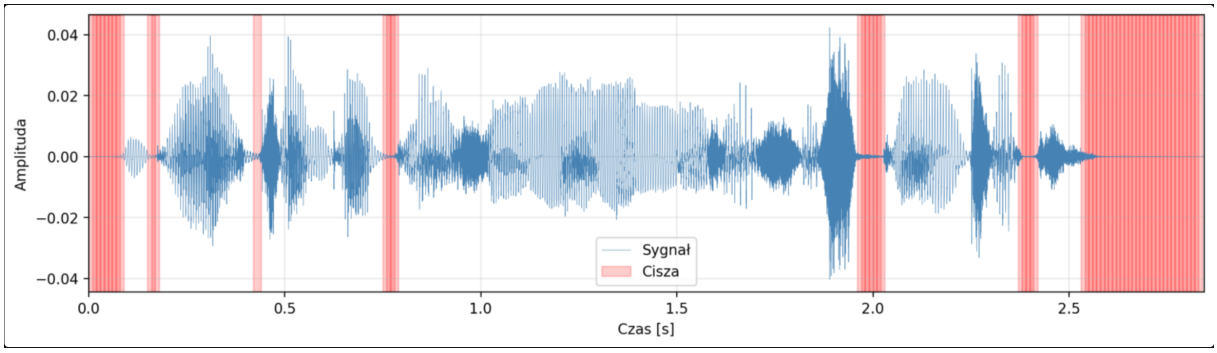

Figure 2: Detekcja ciszy sygnału audio.

2.9 Częstotliwość tonu podstawowego (F_0)

Ton podstawowy wyznaczany jest dwoma metodami działającymi w dziedzinie czasu.

2.9.1 Metoda autokorelacji

Funkcja autokorelacji ramki dla opóźnienia τ wynosi:

$$R(\tau) = \sum_{n=0}^{N-\tau-1} x(n)\, x(n+\tau) \tag{12}$$

Szukamy τ^* dającego maksimum $R(\tau)$ w zakresie $[\tau_{\min},\, \tau_{\max}]$, gdzie $\tau_{\min} = \lfloor f_s/f_{\max} \rfloor$ i $\tau_{\max} = \lfloor f_s/f_{\min} \rfloor$. Częstotliwość tonu podstawowego to:

$$F_0 = \frac{f_s}{\tau^*} \tag{13}$$

Dodatkowo stosowany jest warunek: jeśli $R(\tau^*)/R(0) < 0{,}2$, ramka uznawana jest za beztonową ($F_0 = 0$). Pozwala to odrzucić ramki, w których autokorelacja nie wykazuje wyraźnego piku okresowości.

2.9.2 Metoda AMDF

Average Magnitude Difference Function oblicza średnią różnicę bezwzględną między sygnałem a jego przesuniętą wersją:

$$D(\tau) = \frac{1}{N-\tau} \sum_{n=0}^{N-\tau-1} \Big| x(n) - x(n+\tau) \Big| \tag{14}$$

W przeciwieństwie do autokorelacji, szukamy tu *minimum* $D(\tau)$, ponieważ dla opóźnienia równego okresowi sygnał jest najbardziej podobny do siebie samego. W aplikacji, jako warunek odrzucenia niestabilnych ramek, sprawdzamy czy $D(\tau^*)/|\bar{x}| > 0{,}5$.

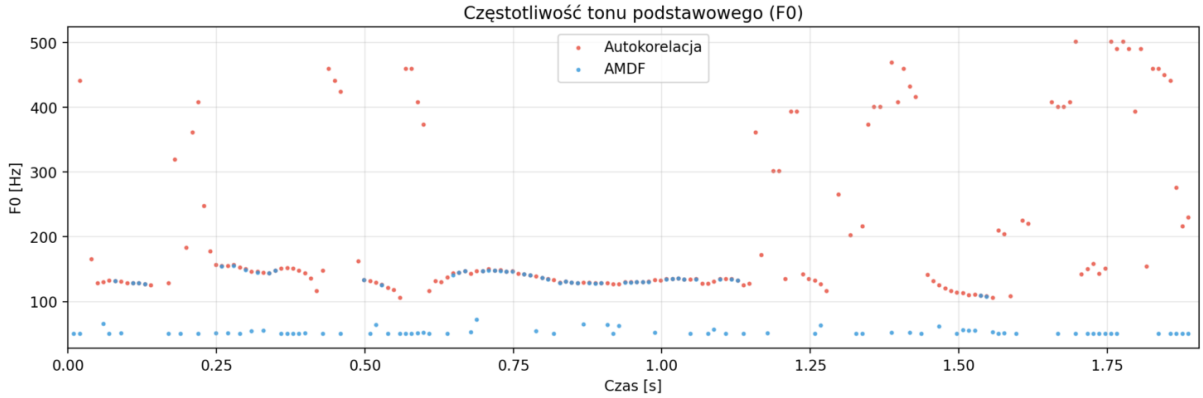

Figure 3: Wykres autokorelacji i AMDF sygnału audio.

2.10 Klasyfikacja: dźwięczne / bezdźwięczne / cisza

Klasyfikacja każdej ramki opiera się na trzech kryteriach:

1. **Cisza (S)** – głośność ramki poniżej progu $r \cdot \max(\text{Volume})$.
2. **Dźwięczna (V)** – ramka nie jest cichą, wykryto ton podstawowy ($F_0 > 0$) i ZCR $<$ próg.
3. **Bezdźwięczna (U)** – pozostałe ramki (wysoki ZCR lub brak wyraźnego F_0).

Użytkownik może regulować oba progi za pomocą suwaków, co pozwala dostosować klasyfikację do różnych typów sygnałów.

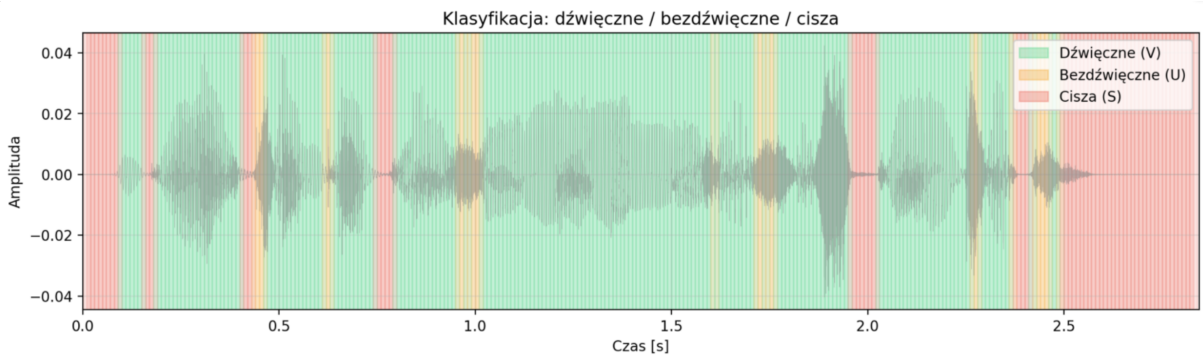

Figure 4: Wykres klasyfikacji na dźwięczne / bezdźwięczne / cisza.

2.11 Parametry na poziomie klipu

Oprócz parametrów ramkowych aplikacja oblicza cechy globalne całego nagrania:

- **LSTER** (Low Short-Time Energy Ratio) – odsetek ramek, których STE jest mniejsza niż połowa średniej STE:

$$\text{LSTER} = \frac{1}{K} \sum_{k=1}^{K} 1_{\left[\text{STE}(k) < 0{,}5 \cdot \overline{\text{STE}}\right]} \tag{15}$$

Wysoka wartość sugeruje mowę (częste fragmenty ciszy między wyrazami).

- **HZCRR** (High Zero-Crossing Rate Ratio) – odsetek ramek z ZCR powyżej 150% średniej:

$$\mathrm{HZCRR} = \frac{1}{K}\sum_{k=1}^{K} 1_{\left[\mathrm{ZCR}(k) > 1{,}5\cdot\overline{\mathrm{ZCR}}\right]} \tag{16}$$

  Wysoka wartość sugeruje muzykę lub szum.

- **ZSTD** – odchylenie standardowe ZCR, miara zmienności sygnału.

- **Entropia energii klipu** – entropia rozkładu energii między wszystkimi ramkami (wzór analogiczny do równania 5, ale sumowanie po ramkach zamiast podramek).

2.12 Rozróżnianie mowy i muzyki

Klasyfikacja realizowana jest metodą heurystyczną, polegającą na analizie zestawu cech sygnału audio. Dla każdej cechy definiowany jest próg decyzyjny, a następnie przyznawane są punkty dodatnie lub ujemne w zależności od tego, czy dana wartość jest charakterystyczna dla muzyki czy mowy. Ostateczna decyzja podejmowana jest na podstawie sumarycznego wyniku punktowego.

3 Prezentacja wyników

W tej sekcji przedstawiono wyniki analizy dla trzech sygnałów: mowy kobiety, mowy mężczyzny oraz fragmentu muzycznego (Mozart).

3.1 Przebieg czasowy

3.1.1 Kobieta

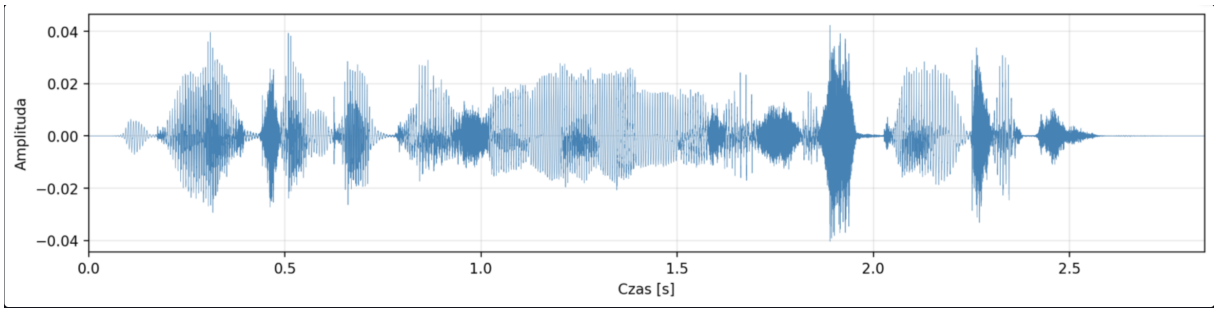

Figure 5: Przebieg czasowy sygnału – kobieta.

3.1.2 Mężczyzna

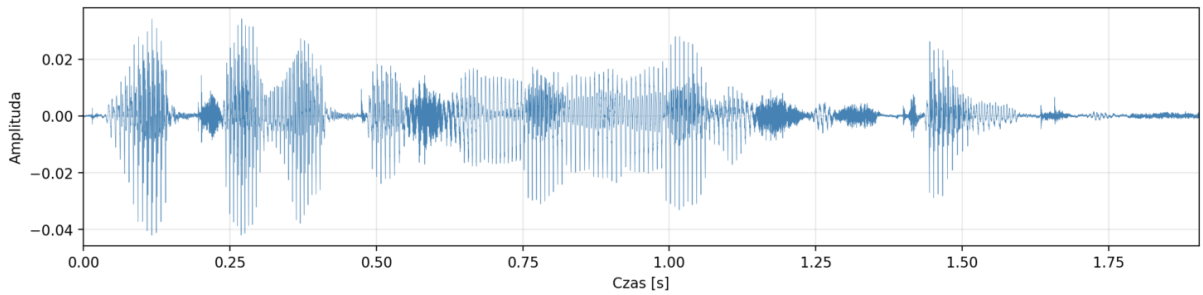

Figure 6: Przebieg czasowy sygnału – mężczyzna.

3.1.3 Muzyka (Mozart)

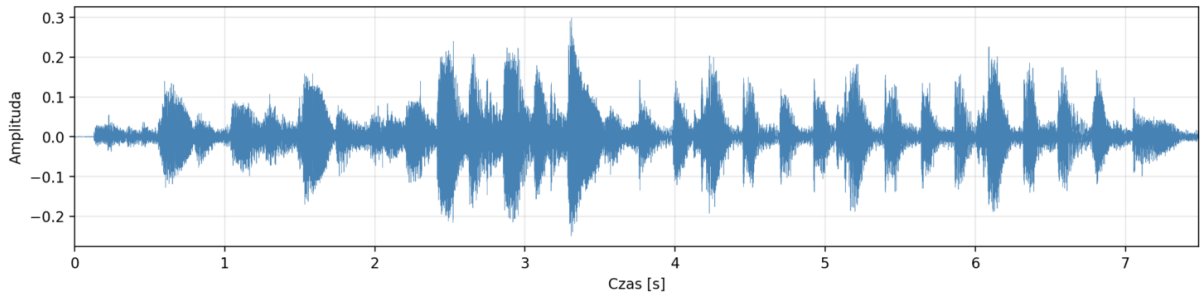

Figure 7: Przebieg czasowy sygnału – muzyka.

Na wykresach czasowych widać, że nagrania mowy mają bardziej segmentowy charakter: pojawiają się w nich wyraźne odcinki aktywności rozdzielone pauzami lub fragmentami o małej amplitudzie. W analizowanym fragmencie muzyki sygnał jest bardziej ciągły i rzadziej przechodzi w dłuższe odcinki bliskie ciszy.

3.2 Parametry ramkowe

3.2.1 Kobieta

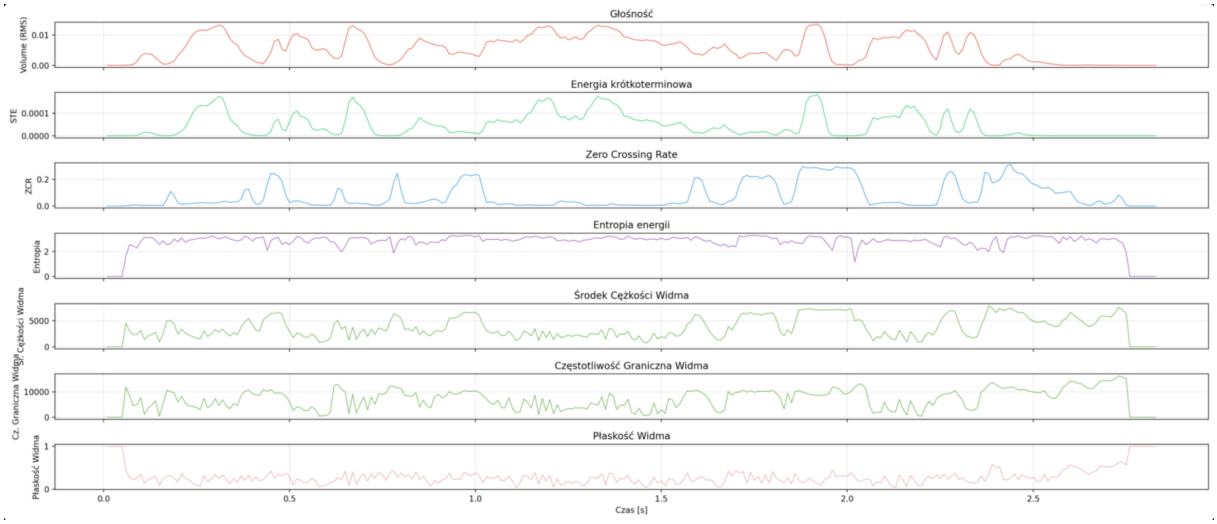

Figure 8: Parametry ramkowe – kobieta.

3.2.2 Mężczyzna

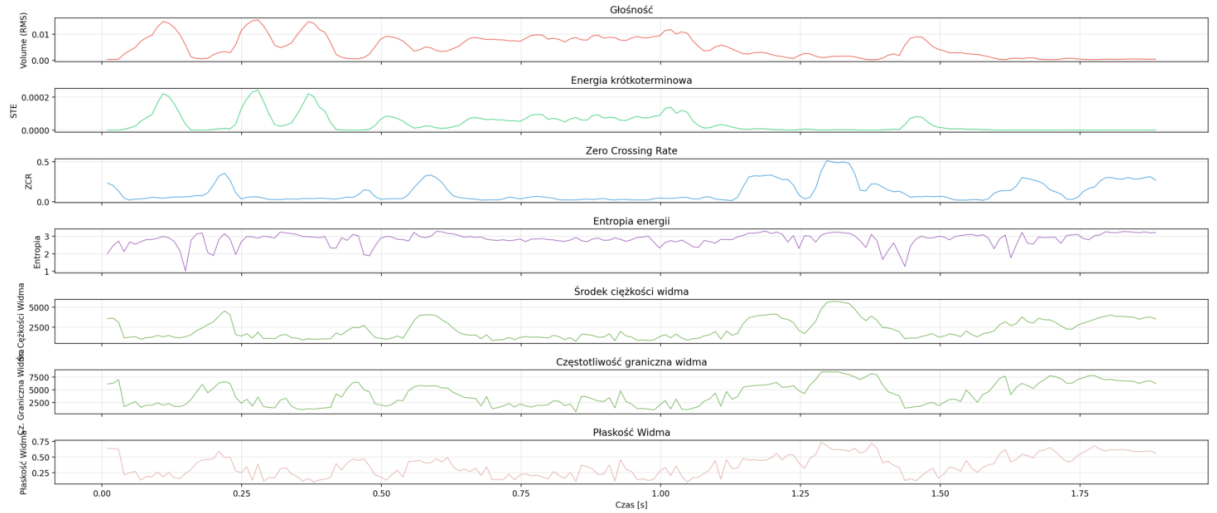

Figure 9: Parametry ramkowe – mężczyzna.

3.2.3 Muzyka (Mozart)

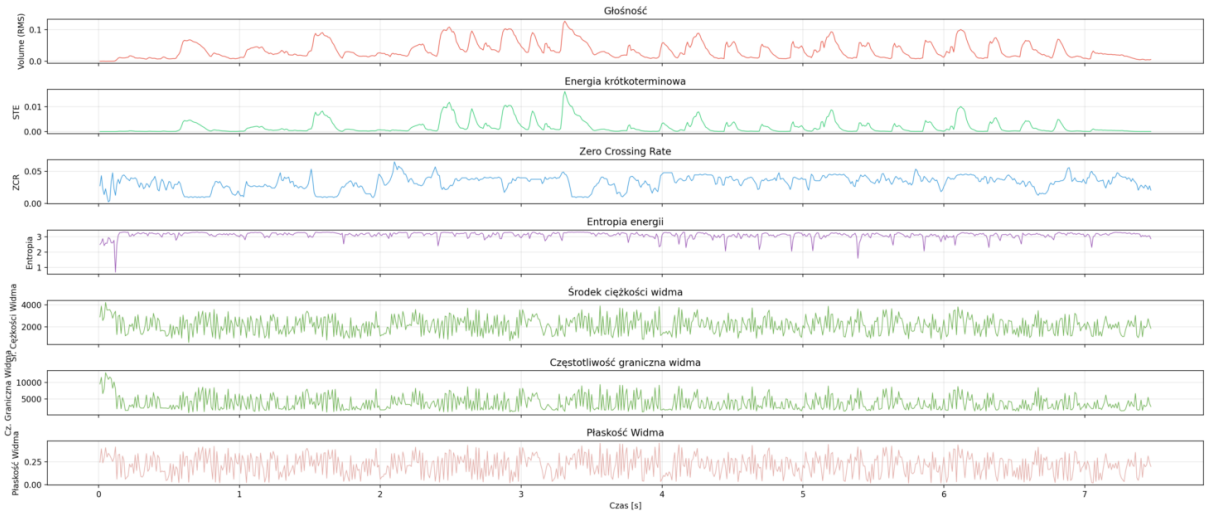

Figure 10: Parametry ramkowe – muzyka.

- Przebiegi Volume i STE są do siebie bardzo podobne dla sygnałów mowy i dobrze odzwierciedlają zmiany amplitudy w czasie. Dla mowy mają one bardziej wyraźnie rozdzielone lokalne maksima i minima, natomiast dla muzyki pozostają aktywne przez większą część nagrania.
- W nagraniach mowy współczynnik ZCR zmienia się bardziej nierównomiernie, co może wskazywać na obecność fragmentów o różnym charakterze, natomiast w muzyce jego przebieg jest bardziej ciągły. Z samego wykresu można więc wnioskować, że parametr ten lepiej pokazuje lokalne zmiany w mowie niż w analizowanym fragmencie muzycznym.
- Cechy widmowe, wykazują znacznie większe wahania w fragmencie utworu niż w nagraniach mowy.

3.3 Częstotliwość tonu podstawowego (F_0)

3.3.1 Kobieta

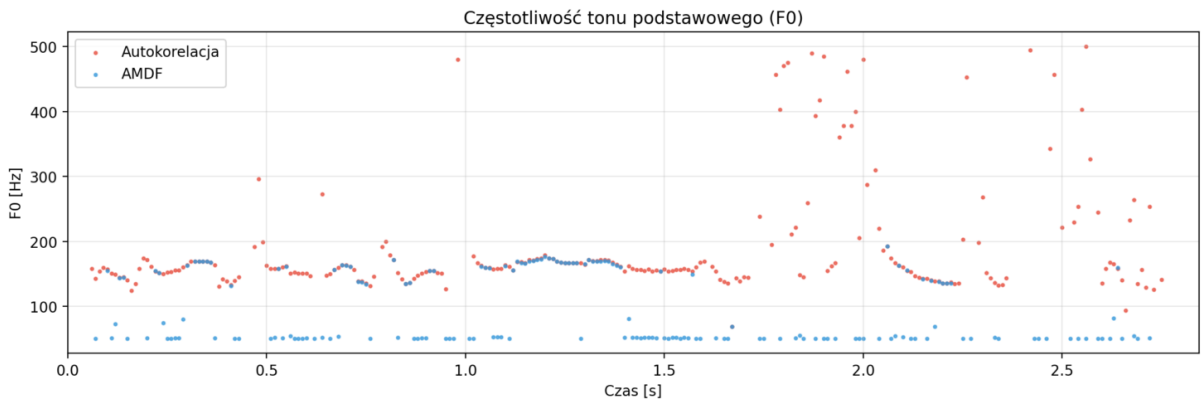

Figure 11: F_0 (autokorelacja i AMDF) – kobieta.

3.3.2 Mężczyzna

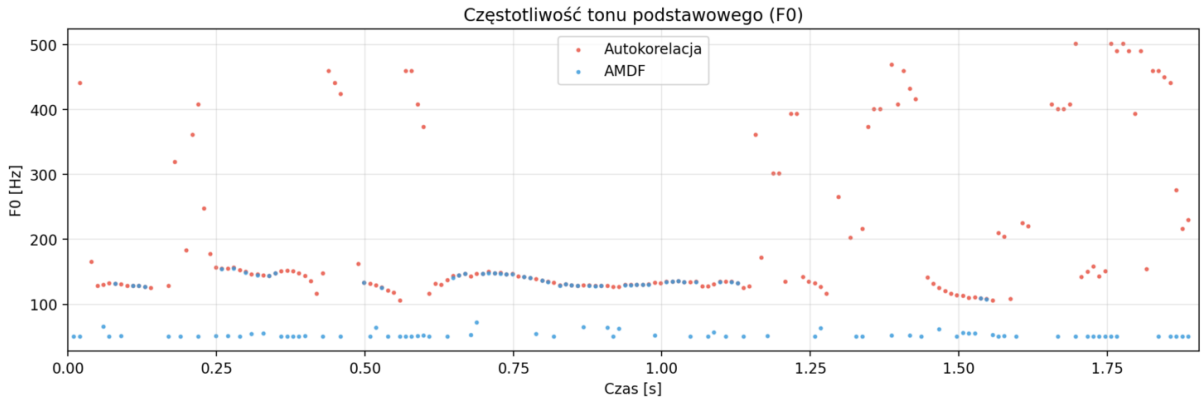

Figure 12: F_0 (autokorelacja i AMDF) – mężczyzna.

3.3.3 Muzyka (Mozart)

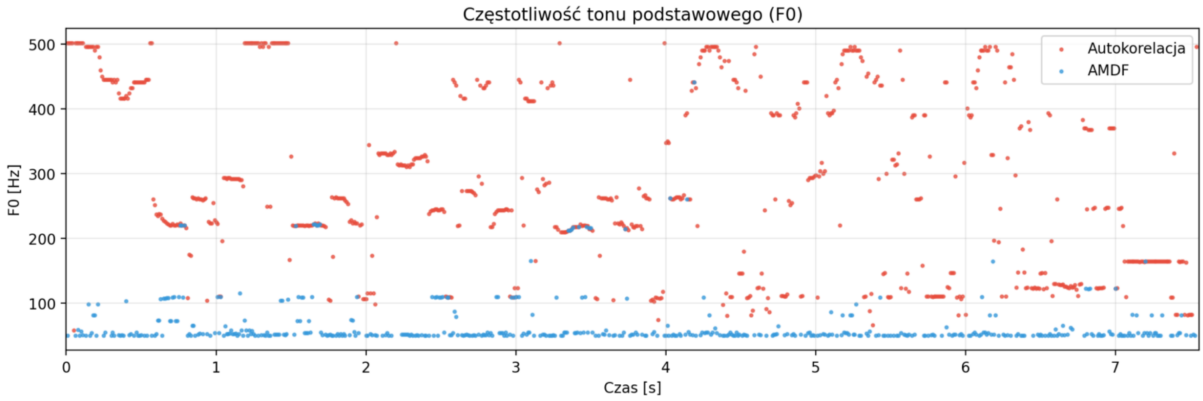

Figure 13: F_0 (autokorelacja i AMDF) – muzyka.

- Wykresy F0 dla głosu kobiecego i męskiego pokazują uporządkowane zakresy wartości w części ramek, przy czym dla kobiety są one na ogół położone wyżej niż dla mężczyzny. Jednocześnie na obu wykresach widać pojedyncze skoki i rozproszone punkty, dlatego estymację tonu podstawowego należy traktować jako częściowo stabilną.

- Dla muzyki wykres F0 jest znacznie bardziej rozproszony niż dla mowy i nie tworzy jednej wyraźnej trajektorii. Na podstawie samej wizualizacji można więc przyjąć, że w tym przypadku wyznaczanie tonu podstawowego jest mniej jednoznaczne niż dla sygnałów mowy.

3.4 Klasyfikacja: dźwięczne / bezdźwięczne / cisza

3.4.1 Kobieta

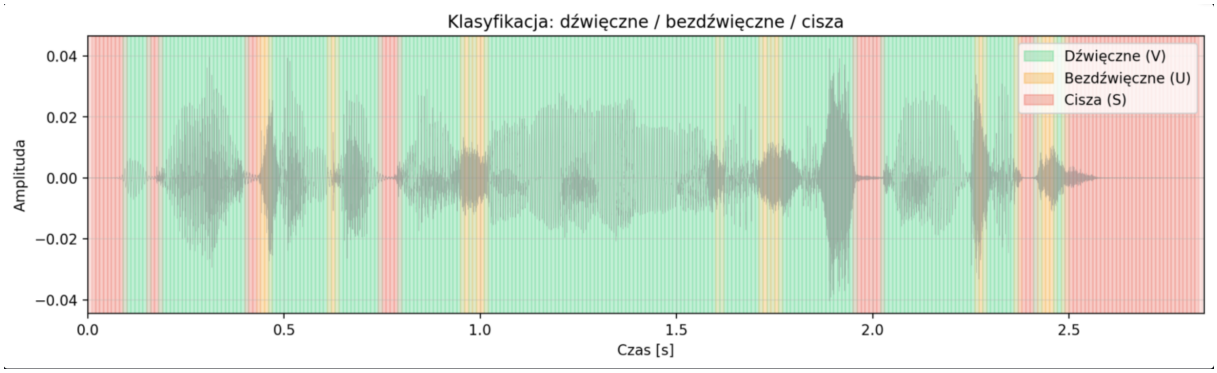

Figure 14: Klasyfikacja – kobieta.

3.4.2 Mężczyzna

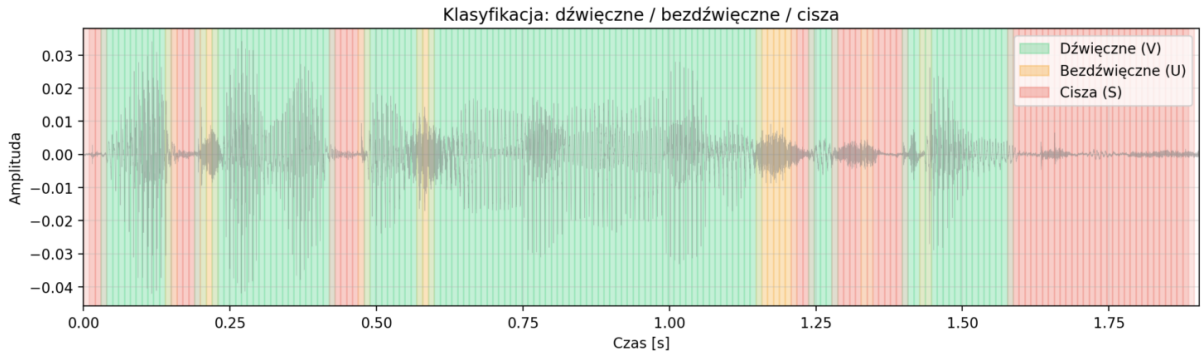

Figure 15: Klasyfikacja – mężczyzna.

3.4.3 Muzyka (Mozart)

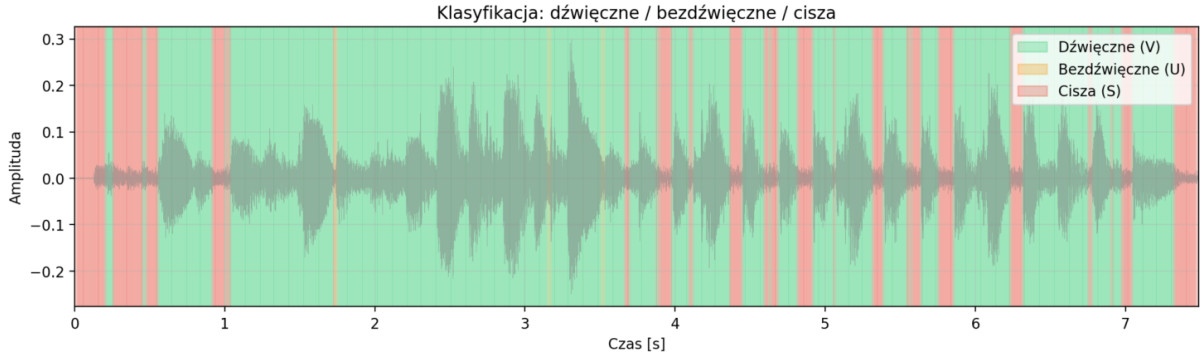

Figure 16: Klasyfikacja – muzyka.

Klasyfikacja dźwięczne / bezdźwięczne / cisza daje najbardziej czytelne wyniki dla mowy, gdzie odcinki ciszy i fragmenty aktywne są dobrze widoczne także na przebiegu czasowym. W muzyce dominują odcinki aktywne, a cisza występuje rzadziej i krócej.

4 Podsumowanie

W ramach projektu przeanalizowano trzy przykładowe sygnały audio: mowę kobiety, mowę mężczyzny oraz muzykę. Uzyskane wykresy pokazały, że zastosowane parametry dobrze opisują zmiany sygnału w czasie i pozwalają zauważyć różnice między mową a muzyką. Najbardziej widoczne były różnice w ciągłości sygnału, liczbie pauz oraz w przebiegu częstotliwości podstawowej. Przeprowadzona analiza potwierdziła, że badane cechy są użyteczne w podstawowej analizie i porównywaniu sygnałów audio.