Analiza i Przetwarzanie Dzwięku

Rok akademicki 2025/26

Projekt 2

Analiza częstotliwościowa

Ryszard Czarnecki
Józef Dubois

Kwiecień 2026

Contents

1 Opis aplikacji **2**
1.1 Struktura projektu 2
1.2 Użyte biblioteki 2

2 Opis metod **2**
2.1 Segmentacja sygnału 2
2.2 Transformata Fouriera (FFT) 3
2.3 Funkcje okienkowe 3
2.4 Widmo dla całego sygnału i pojedynczej ramki 4
2.5 Spektrogram 4
2.6 Cepstrum i estymacja częstotliwości podstawowej 5
2.7 Estymacja formantów 5
2.8 Interaktywność aplikacji 5

3 Różnica między spółgłoskami a samogłoskami. **6**
3.1 Wyniki pomiarów 6
3.2 Analiza wyników 7
3.2.1 Porównanie segmentów 8
3.2.2 Analiza spektrogramu i cepstrum 9
3.2.3 Wpływ funkcji okna 10
3.3 Wnioski 11

4 Podsumowanie **11**

1 Opis aplikacji

Aplikacja została zaimplementowana w języku Python z wykorzystaniem biblioteki `Streamlit`, poszerzono implementację z projektu 1.

1.1 Struktura projektu

- **parameters.py** – obliczanie parametrów sygnału w dziedzinie czasu i częstotliwości,
- **windows.py** – implementacja funkcji okienkowych,
- **spectrum.py** – analiza widmowa, FFT, spektrogram, cepstrum, formanty,
- **pitch.py** – estymacja częstotliwości podstawowej (autokorelacja, AMDF),
- **parameters_over_clip.py** – parametry globalne dla całego sygnału,
- **main_app.py** – interfejs użytkownika oraz integracja wszystkich funkcji,
- **voiced_unvoiced.py** – wykrywanie fragmentów dźwięcznych/bezdźwięcznych,
- **silence_detection.py** – wykrywanie ciszy,
- **wav_reader.py** – wczytywanie ścieżek dźwiękowych.

1.2 Użyte biblioteki

- **NumPy** – operacje na tablicach numerycznych, normalizacja próbek, fft,
- **Matplotlib** – generowanie wykresów (przebieg czasowy, parametry, pitch, klasyfikacja),
- **Streamlit** – interfejs webowy z widgetami (suwaki, pola numeryczne, przyciski pobierania),
- **Pandas** – eksport parametrów do pliku CSV.

2 Opis metod

Poniżej opisane są jedynie rzeczy dodane do aplikacji w ramach projektu 2. Opis pozostałych metod znajduje się w sprawozdaniu raportu 1.

2.1 Segmentacja sygnału

Sygnał wejściowy dzielony jest na ramki o zadanej długości (w milisekundach) z określonym nakładaniem (overlap). Dla każdej ramki obliczane są parametry czasowe i częstotliwościowe.

Długość ramki wyrażona w próbkach:

$$N = f_s \cdot \frac{T_{frame}}{1000}$$

Przesunięcie między ramkami:

$$hop = N \cdot (1 - overlap)$$

2.2 Transformata Fouriera (FFT)

Do analizy widmowej wykorzystano szybką transformatę Fouriera (FFT) z biblioteki NumPy.

Widmo amplitudowe wyznaczane jest jako:

$$X(k) = \left| \sum_{n=0}^{N-1} x(n) e^{-j2\pi kn/N} \right|$$

W implementacji wykorzystano tylko połowę widma (do częstotliwości Nyquista), co wynika z symetrii dla sygnałów rzeczywistych.

Dodatkowo obliczana jest skala logarytmiczna:

$$X_{dB}(k) = 20 \log_{10}(X(k) + \epsilon)$$

2.3 Funkcje okienkowe

Przed wykonaniem FFT sygnał jest mnożony przez funkcję okienkową w celu redukcji zjawiska przecieku widma (spectral leakage).

Zaimplementowano następujące okna:

- okno prostokątne:
$$w(n) = 1$$
- okno trójkątne:
$$w(n) = 1 - \left| \frac{n - (N-1)/2}{(N-1)/2} \right|$$
- okno Hamminga:
$$w(n) = 0.54 - 0.46 \cos\left(\frac{2\pi n}{N-1}\right)$$
- okno Hann (von Hanna):
$$w(n) = 0.5 \left(1 - \cos\left(\frac{2\pi n}{N-1}\right)\right)$$
- okno Blackmana:
$$w(n) = 0.42 - 0.5 \cos\left(\frac{2\pi n}{N-1}\right) + 0.08 \cos\left(\frac{4\pi n}{N-1}\right)$$

Dla każdej funkcji analizowany jest zarówno przebieg w dziedzinie czasu, jak i jej widmo.

2.4 Widmo dla całego sygnału i pojedynczej ramki

Aplikacja umożliwia:

- analizę FFT dla całego sygnału,
- analizę FFT dla wybranej ramki sygnału,
- porównanie wpływu różnych funkcji okienkowych na widmo.

Dla pojedynczej ramki prezentowane są:

- sygnał oryginalny,
- sygnał po zastosowaniu okna,
- widmo amplitudowe,
- widmo w skali dB.

2.5 Spektrogram

Spektrogram został zaimplementowany samodzielnie poprzez:

1. podział sygnału na ramki,
2. zastosowanie funkcji okna,
3. obliczenie FFT dla każdej ramki,
4. zapisanie logarytmicznej amplitudy widma.

Wynik przedstawiany jest jako mapa:

- oś X – czas,
- oś Y – częstotliwość,
- kolor – amplituda w dB.

Użytkownik może regulować:

- długość ramki,
- overlap,
- funkcję okna.

2.6 Cepstrum i estymacja częstotliwości podstawowej

Cepstrum obliczane jest jako odwrotna transformata Fouriera logarytmu widma:

$$c(n) = \mathcal{F}^{-1}\left(\log|\mathcal{F}(x(n))|\right)$$

Na jego podstawie wyznaczana jest częstotliwość podstawowa F_0 poprzez znalezienie maksimum w odpowiednim zakresie quefrencji:

$$F_0 = \frac{f_s}{q_{max}}$$

gdzie q_{max} to indeks maksimum cepstrum w zadanym zakresie.

Wynik prezentowany jest oddzielnie od autokorelacji i AMDF.

2.7 Estymacja formantów

Formanty wyznaczane są bezpośrednio z widma FFT poprzez wygładzenie obwiedni spektralnej ruchomą średnią i detekcję lokalnych maksimów.

Wygładzanie realizowane jest jako splot widma amplitudowego z oknem prostokątnym o długości k:

$$\tilde{X}(m) = \frac{1}{k}\sum_{i=m-k/2}^{m+k/2} X(i)$$

Parametr k dobierany jest tak, aby wygładzić harmoniczne sygnału mowy (rozłożone co $F_0 \approx$ 100–150 Hz), zachowując jednocześnie szerokie rezonanse traktu głosowego (formanty).

Spośród wykrytych lokalnych maksimów wybierane są kandydaci spełniający warunek:

$$f_{min} < f < f_{max}$$

gdzie przyjęto $f_{min} = 90$ Hz oraz $f_{max} = 4000$ Hz. Zwracane jest n najsilniejszych pików posortowanych według częstotliwości, interpretowanych jako kolejne formanty F1, F2, F3.

Należy zaznaczyć, że metoda ta jest przybliżona, w przeciwieństwie do analizy LPC (Linear Predictive Coding), nie modeluje bezpośrednio charakterystyki traktu głosowego, przez co może identyfikować harmoniczne wysokiej energii zamiast rzeczywistych formantów. Stanowi jednak prostą i poglądową metodę estymacji w ramach analizy FFT.

2.8 Interaktywność aplikacji

Aplikacja umożliwia dynamiczną zmianę parametrów analizy:

- długości ramki,
- overlap,
- zakresu F_0,
- wyboru funkcji okna,
- wyboru analizowanej ramki.

Dzięki temu możliwe jest obserwowanie wpływu parametrów na wyniki analizy w czasie rzeczywistym.

3 Różnica między spółgłoskami a samogłoskami.

Aby zbadać różnice między spółgłoskami a samogłoskami zbadano nagranie słowa „abe". Zostało ono podzielone na trzy segmenty odpowiadające poszczególnym głoskom: samogłosce *a*, spółgłosce *b* oraz samogłosce *e*. Dla każdego segmentu wyznaczono trzy pierwsze formanty (F1, F2, F3) na podstawie analizy cepstralnej i widmowej.

3.1 Wyniki pomiarów

Table 1: Wartości formantów dla poszczególnych segmentów nagrania „abe" policzonych dla widma FFT z oknem Prostokątnym.

Segment	**F1 [Hz]**	**F2 [Hz]**	**F3 [Hz]**
a	900,0	1025,0	1125,0
b	277,7	333,3	355,6
e	389,1	511,4	622,0

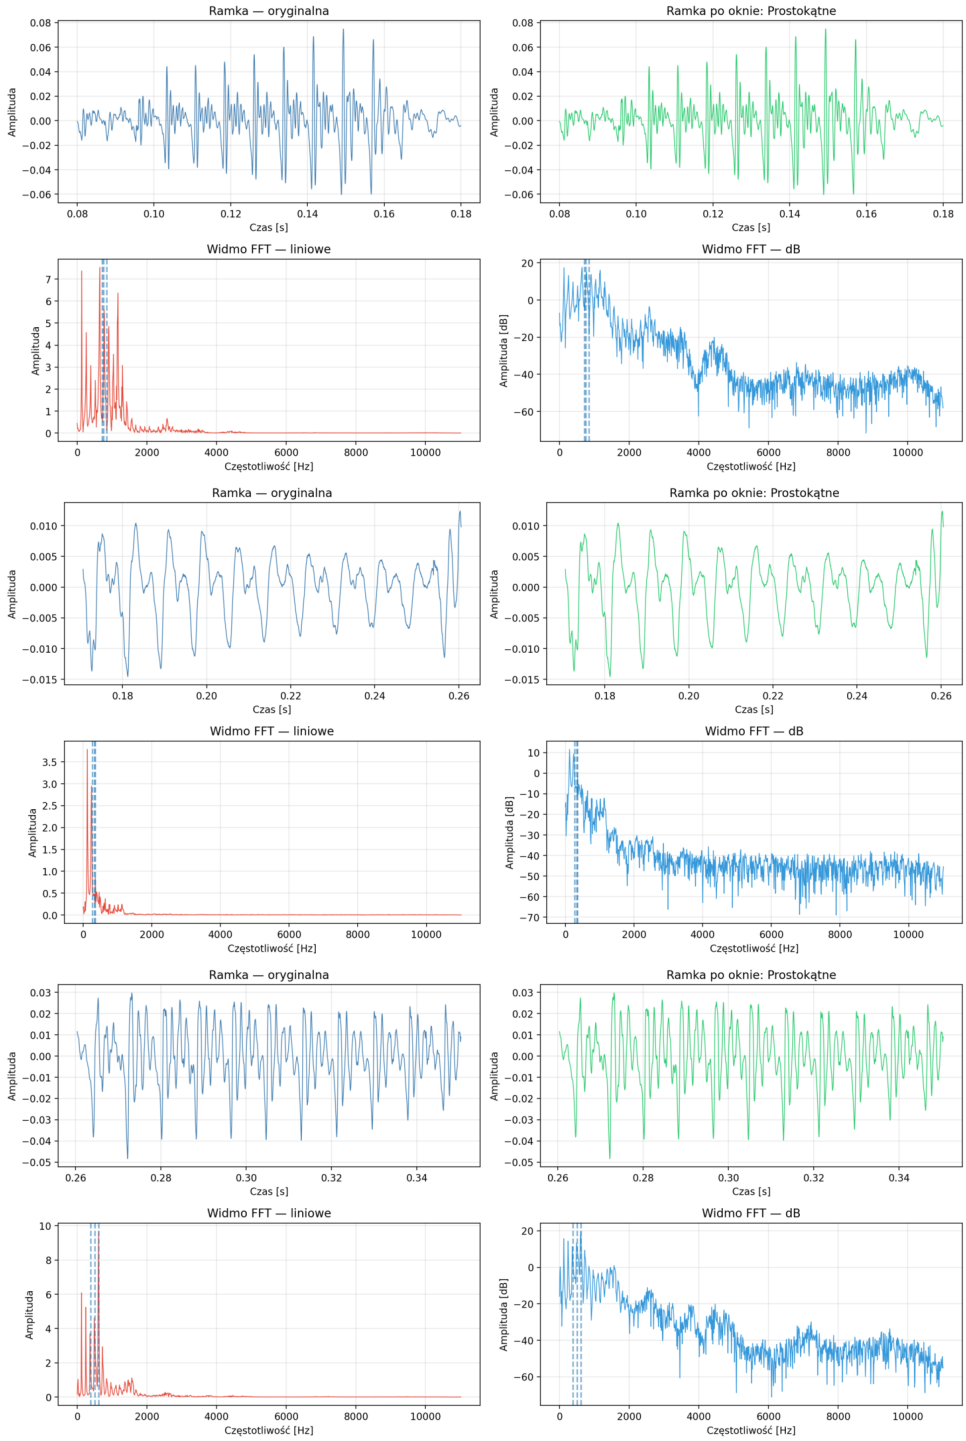

Figure 1: Widmo FFT z zaznaczonymi formantami dla segmentów a, b oraz e.

3.2 Analiza wyników

Uzyskane wartości formantów częściowo odbiegają od wartości referencyjnych podawanych w literaturze fonetycznej. Dla samogłoski a typowe wartości formantów (mężczyzna) wynoszą: F1 $\approx$ 700–800 Hz, F2 $\approx$ 1200–1400 Hz, F3 $\approx$ 2500–2800 Hz. Dla samogłoski e: F1 $\approx$ 400–500 Hz, F2 $\approx$ 1800–2200 Hz, F3 $\approx$ 2500–2800 Hz.

Wartość F1 dla samogłoski a (900 Hz) mieści się w pobliżu przedziału referencyjnego, natomiast F2 i F3 są wyraźnie zaniżone. Dla samogłoski e F1 (389 Hz) jest zgodny

z literaturą, jednak F2 i F3 są znacząco niższe od oczekiwanych. Rozbieżności te wynikają prawdopodobnie z ograniczeń zastosowanej metody estymacji – wygładzanie obwiedni spektralnej ruchomą średnią nie eliminuje w pełni wpływu harmonicznych sygnału mowy, przez co algorytm może identyfikować harmoniczne wysokiej energii zamiast rzeczywistych formantów. Dokładniejszą estymację umożliwiłaby metoda LPC (Linear Predictive Coding), która modeluje obwiednię spektralną bez konieczności wygładzania.

Dla spółgłoski *b* uzyskane wartości (F1 $\approx$ 278 Hz, F2 $\approx$ 333 Hz, F3 $\approx$ 356 Hz) nie powinny być interpretowane jako formanty w klasycznym sensie. Spółgłoska zwarta *b* charakteryzuje się krótką okluzją, po której następuje gwałtowne uwolnienie energii. Na tak krótkim i niekwazistacjonarnym fragmencie sygnału estymacja formantów metodą FFT jest z założenia zawodna, a uzyskane wartości odzwierciedlają raczej strukturę harmoniczną otaczających samogłosek lub artefakty numeryczne.

3.2.1 Porównanie segmentów

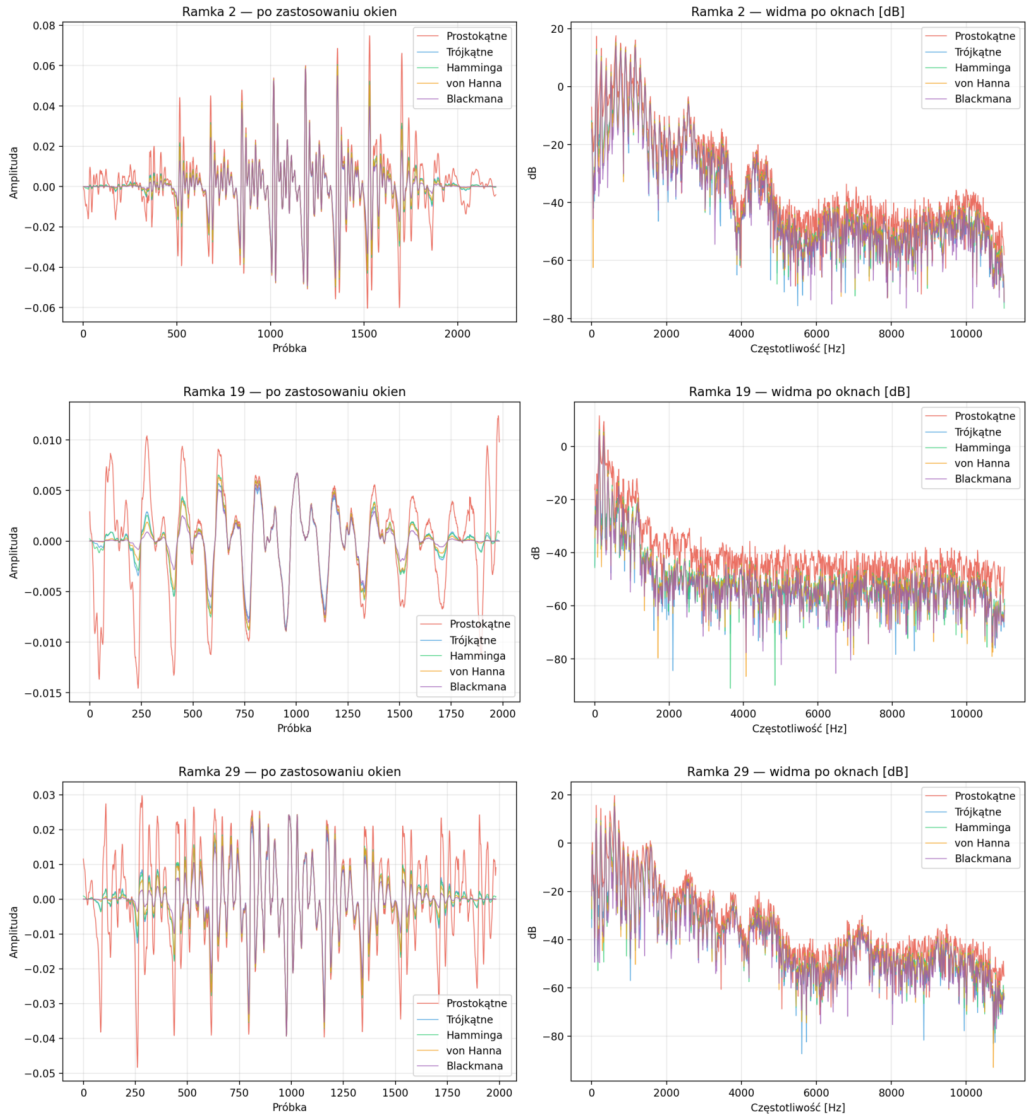

Figure 2: Porównanie widm FFT dla różnych funkcji okna – segmenty *a* (górny), *b* (środkowy) i *e* (dolny).

Mimo że wartości bezwzględne nie odpowiadają typowym formantom, można zaobserwować pewne prawidłowości:

- Segment *a* wykazuje najwyższe wartości F1 i F2 spośród wszystkich segmentów (F1 = 900 Hz, F2 = 1025 Hz), co jest zgodne z fonetyczną charakterystyką samogłoski tylnej otwartej, szeroko otwarty trakt głosowy skutkuje wysokim F1.
- Segment *e* ma niższe F1 (389 Hz) niż *a*, co odpowiada mniej otwartej artykulacji samogłoski przedniej. Różnica między F1 a F2 jest większa niż dla *a*, co jakościowo odzwierciedla charakterystyczny układ formantów samogłosek przednich.
- Dla segmentu *b* uzyskane wartości (F1 = 278 Hz, F2 = 333 Hz, F3 = 356 Hz) są najniższe i skupione w wąskim paśmie niskich częstotliwości. Jak wspomniano wcześniej, nie należy ich interpretować jako formantów – mogą one odpowiadać składowym harmonicznym sąsiednich samogłosek lub artefaktom wynikającym z krótkości i niekvazistacjonarności segmentu.

3.2.2 Analiza spektrogramu i cepstrum

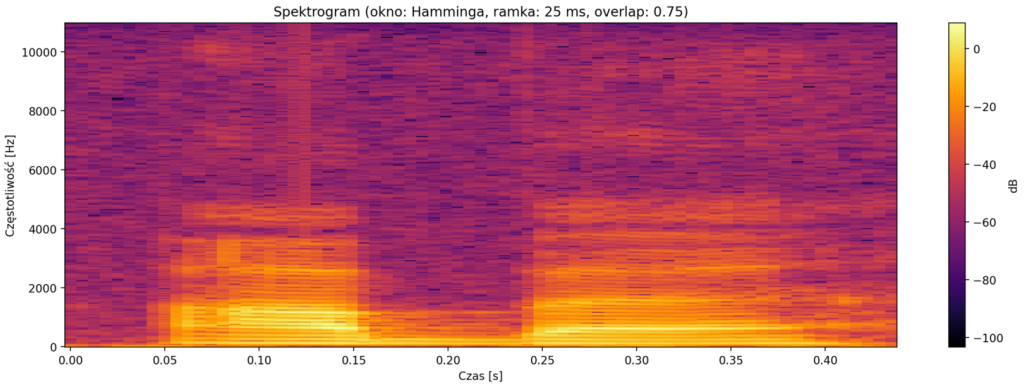

Figure 3: Spektrogram nagrania „abe” z widoczną strukturą harmoniczną segmentów samogłoskowych.

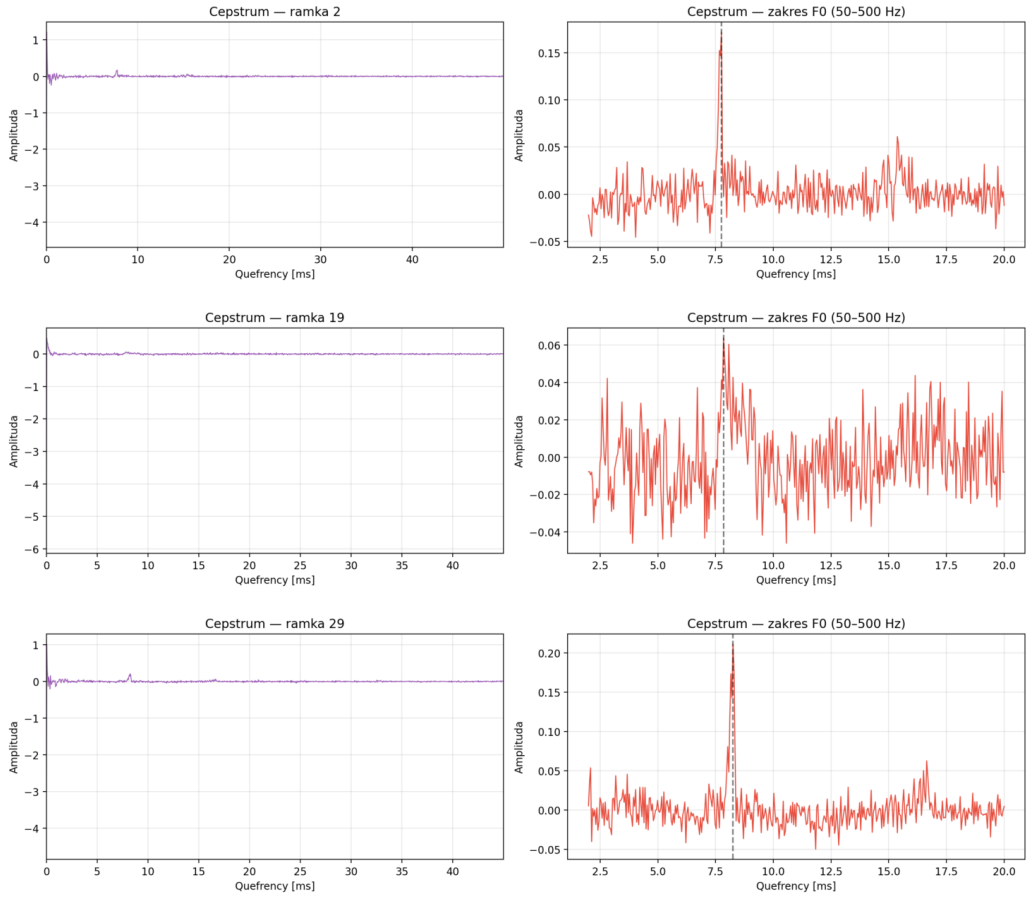

Figure 4: Cepstrum segmentów a (górny), b (środkowy) i e (dolny) z widocznym pikiem przy $\tau \approx 8$ ms odpowiadającym F0 $\approx$ 125 Hz.

Spektrogram nagrania „abe” uwidacznia wyraźne różnice między segmentami:

- W segmentach samogłoskowych (a, e) widoczna jest regularna struktura harmoniczna — równomiernie rozłożone pasma energii odpowiadające kolejnym harmonicznym F0.
- Segment b charakteryzuje się krótkim przerwaniem struktury harmonicznej (faza zwarcia) i następującym szerokopasmowym impulsem (faza wybuchu).
- Analiza cepstralna wykazała wyraźny pik w okolicach kwefrencji $\tau \approx 8$ ms, co odpowiada $F0 = 1/\tau \approx 125$ Hz. Pik ten jest dobrze widoczny w segmentach dźwięcznych (a, b, e).

3.2.3 Wpływ funkcji okna

Porównanie różnych funkcji okna (prostokątne, trójkątne, Hamminga, von Hanna, Blackmana) na widmo FFT wykazało:

- Okno prostokątne daje najwęższe pasmo główne, ale największy poziom listków bocznych (spectral leakage), co utrudnia rozróżnienie bliskich składowych częstotliwościowych.
- Okna Hamminga i von Hanna skutecznie tłumią listki boczne (o ok. 40–50 dB) kosztem niewielkiego poszerzenia pasma głównego.

- Okno Blackmana zapewnia najlepsze tłumienie listków bocznych (ponad 70 dB), ale najszersze pasmo główne, co obniża rozdzielczość częstotliwościową.

3.3 Wnioski

1. Wyznaczone wartości formantów nie odpowiadają wartościom referencyjnym z literatury fonetycznej. Prawdopodobną przyczyną jest to, że algorytm identyfikuje piki harmonicznych F0 w widmie zamiast rezonansów traktu głosowego (formantów). Poprawne wyznaczanie formantów wymaga zastosowania analizy LPC (Linear Predictive Coding) lub metody obwiedni widmowej.

2. Pomimo tego ograniczenia, relacje między wartościami formantów poszczególnych segmentów zachowują pewną spójność z oczekiwaniami fonetycznymi (np. wyższe wartości dla *b* wynikające z szerokopasmowego charakteru spółgłoski zwartej).

3. Analiza cepstralna poprawnie identyfikuje częstotliwość podstawową F0 $\approx$ 125 Hz, co jest wartością typową dla męskiego głosu.

4. Porównanie funkcji okna potwierdza teoretyczny kompromis między rozdzielczością częstotliwościową a tłumieniem listków bocznych. Dla analizy mowy okno Hamminga stanowi dobry kompromis.

5. Spektrogram poprawnie wizualizuje strukturę czasowo-częstotliwościową nagrania, umożliwiając rozróżnienie segmentów samogłoskowych i spółgłoskowych.

4 Podsumowanie

W ramach projektu zaimplementowano aplikację do analizy częstotliwościowej sygnałów dźwiękowych, stanowiącą rozbudowę projektu 1. Aplikacja umożliwia analizę widmową poprzez FFT dla całego sygnału oraz wybranych ramek, zastosowanie pięciu funkcji okienkowych, rysowanie spektrogramu z regulowanymi parametrami, estymację częstotliwości podstawowej metodą cepstralną oraz wyznaczanie formantów.

Analiza nagrania słowa „abe” pozwoliła zaobserwować wyraźne różnice między samogłoskami a spółgłoską w dziedzinie częstotliwości. Segmenty samogłoskowe (*a*, *e*) charakteryzują się regularną strukturą harmoniczną widoczną zarówno w widmie FFT, jak i na spektrogramie. Segment spółgłoski zwartej *b* wyróżnia się krótką przerwą w strukturze harmonicznej (faza okluzji) i szerokopasmowym impulsem wybuchu – cechy te są wyraźnie rozróżnialne na spektrogramie.

Analiza cepstralna poprawnie wyznaczyła częstotliwość podstawową $F_0 \approx 125$ Hz, co odpowiada typowej wartości dla głosu męskiego. Estymacja formantów metodą wygładzania obwiedni spektralnej dała wyniki częściowo zgodne z oczekiwaniami fonetycznymi, F1 samogłosek mieści się w pobliżu wartości referencyjnych, natomiast F2 i F3 są zaniżone ze względu na ograniczenia metody. Dokładniejszą estymację umożliwiłoby zastosowanie analizy LPC.

Porównanie funkcji okienkowych potwierdziło teoretyczny kompromis między rozdzielczością częstotliwościową a tłumieniem listków bocznych. Okno prostokątne zapewnia najlepszą rozdzielczość kosztem wycieku widma, natomiast okno Blackmana minimalizuje wyciek kosztem rozdzielczości. Dla analizy sygnału mowy okno Hamminga stanowi dobry kompromis między obiema właściwościami.